

# Procesamiento Big Data con Scala

*Módulo 1 · Sesión 2 · Día 1*

---

IFCD0115 · Introducción al Procesamiento de Big Data



# 01

## BLOQUE TEÓRICO

*Aplicaciones e importancia de Big Data en la industria ·*



## Agenda — Sesión 2



### Bloque Teórico

- Big Data en Retail, Finanzas, Sanidad y Telecomunicaciones
- El stack tecnológico completo: Hadoop, Spark, Kafka, Hive
- ¿Por qué Spark es el motor central del ecosistema?
- Datos como ventaja competitiva: casos de éxito reales



### Bloque Práctico

- Práctica 1: Investigación guiada de un caso real
- Práctica 2: Construir el mapa conceptual del stack
- Práctica 3: Relacionar herramientas con sus funciones



# Big Data en Retail y E-commerce

## El problema antes del Big Data

- Stock calculado con hojas de cálculo y experiencia del comprador
- Campañas de marketing enviadas a todos los clientes por igual
- Devoluciones difíciles de predecir: pérdidas millonarias
- Colas en tienda sin previsión de afluencia

## Qué cambió con Big Data

- Análisis de millones de transacciones para predecir demanda
- Personalización: cada cliente ve ofertas distintas
- Gestión de inventario en tiempo real, tienda a tienda

## Caso real: Amazon

- Procesa 1,6 millones de pedidos al día
- Sistema de recomendación genera el 35% de sus ingresos
- Anticipa compras antes de que el cliente pulse "comprar"
- (sistema de "envío anticipado" — patente registrada)

## Caso real: Inditex / Zara

- Repone stock en 48h usando ventas en tiempo real
- Reduce colecciones fallidas: solo produce lo que ya se vende
- 600 diseñadores toman decisiones basadas en datos de 7.000 tiendas



# Big Data en Finanzas y Banca

## Detección de fraude en tiempo real

- Se analizan más de 150 variables por transacción
- Decisión en menos de 100 milisegundos
- Visa bloquea 2.500 millones de dólares en fraude al año con ML

## Scoring crediticio alternativo

- Antes: solo se usaban nómina, historial bancario y DNI
- Ahora: comportamiento en redes, pagos de servicios, geolocalización
- BBVA en España usa Big Data para incluir a más clientes sin historial

## Trading algorítmico (HFT)

- Se ejecutan millones de operaciones por segundo
- Decisiones tomadas en microsegundos con datos de mercado global
- El 60-70% del volumen de la bolsa de EEUU es trading algorítmico

## Gestión del riesgo

- Modelos predicen quiebras de empresas con meses de antelación
- Análisis de correlaciones entre activos en tiempo real
- JP Morgan procesa 12.000 millones de eventos al día



# Big Data en Sanidad

## Diagnóstico asistido por IA

- Google DeepMind detecta 50+ enfermedades en retinografías con precisión de oftalmólogo
- IBM Watson oncología analiza miles de artículos científicos para proponer tratamientos
- En España: el Hospital La Fe (Valencia) usa IA para detectar sepsis 6 horas antes

## Predicción de epidemias y salud pública

- Durante COVID-19: modelos de Big Data predijeron la expansión con 2 semanas de antelación
- Google Flu Trends (2008): primera vez que Big Data superó al CDC en velocidad
- Ahora: sistemas de vigilancia epidemiológica en tiempo real en toda la UE

## Medicina personalizada (Precision Medicine)

- Secuenciación del genoma + historial clínico + hábitos → tratamiento 100% personalizado
- El proyecto 100.000 Genomas del NHS (UK) cambió los protocolos de cáncer infantil
- Reto ético: ¿quién es dueño de los datos de salud?



# Big Data en Telecomunicaciones y otros sectores

## Telecomunicaciones

- Análisis de la red en tiempo real: millones de llamadas/datos simultáneos
- Predicción de churning: detectar qué cliente va a darse de baja antes de que ocurra
- Caso: Telefónica usa Big Data para personalizar tarifas y reducir fuga de clientes

## Transporte y Logística

- UPS optimiza rutas con ORION: 100 millones de km menos al año
- Ahorro: 10 millones de galones de combustible · 100.000 Tm de CO2
- Uber / Cabify: precios dinámicos calculados con demanda en tiempo real

## Energía y Utilities

- Smart grids: predicción de consumo eléctrico hora a hora por zona
- Iberdrola analiza millones de lecturas de contadores inteligentes
- Detección de fraude eléctrico: consumos anómalos en tiempo real

## Agricultura de precisión

- Sensores en el campo + datos meteorológicos + imágenes satélites
- Predicción de cosechas, optimización de riego y fertilizantes
- John Deere: tractores con Big Data integrado de fábrica



# El Stack Tecnológico Big Data

01

## Apache Hadoop

- Framework de almacenamiento distribuido (HDFS)
- Motor de procesamiento: MapReduce
- Diseñado para petabytes en hardware barato
- Nacido en Google/Yahoo (2006), ahora Apache
- → Fortaleza: tolerancia a fallos y escalabilidad

02

## Apache Spark

- Procesamiento en memoria: 100x más rápido que Hadoop
- Soporta: batch, streaming, ML y grafos
- Scala es su lenguaje nativo
- La API más usada en la industria hoy
- → Nuestro protagonista durante el curso

03

## Apache Kafka + Hive

- Kafka: sistema de mensajería distribuida
- Ingesta millones de eventos/seg en tiempo real
- Hive: SQL sobre datos en HDFS/S3
- Permite a analistas usar SQL estándar
- → Kafka = autopista de datos · Hive = acceso SQL



# ⚡ ¿Por qué Spark es el motor central?

## Problema de Hadoop MapReduce

- Cada paso de procesamiento escribe resultados en disco (HDFS)
- Para algoritmos iterativos (como Machine Learning): lentísimo
- Ejemplo: un modelo de ML con 10 iteraciones → 10 escrituras en disco

## La solución de Spark: procesamiento en memoria

- Los datos intermedios se guardan en RAM, no en disco
- Resultado: 10x-100x más rápido que MapReduce en batch
- En streaming: latencia de milisegundos vs. Minutos


## Spark es una navaja suiza

- Spark Core → procesamiento distribuido (RDDs, DataFrames)
- Spark SQL → consultas con sintaxis SQL estándar
- Spark Streaming → análisis en tiempo real
- MLlib → machine learning distribuido
- GraphX → análisis de grafos (redes sociales, rutas)

En este curso aprenderemos Spark Core + Spark SQL + MLlib con Scala.

# ⚡ ¿Por qué Spark es el motor central?

## LA EVOLUCIÓN DEL PROCESAMIENTO (MapReduce a Spark)



## SPARK: LA NAVAJA SUIZA Y EL ENFOQUE DEL CURSO



### ENFOQUE DEL CURSO: LO QUE APRENDERÁS



INSTALACIÓN Y CONFIGURACIÓN



ANÁLISIS DE DATOS CON DATAFRAMES



PROCESAMIENTO DE STREAMING EN TIEMPO REAL



DESARROLLO DE MODELOS DE MACHINE LEARNING BÁSICOS



OPTIMIZACIÓN Y SINTONIZACIÓN



INTEGRACIÓN CON ECOSISTEMAS



# Casos de Éxito Reales

## Empresas que transformaron su negocio gracias al procesamiento inteligente de datos masivos:



### Netflix

- Procesa 500 millones de eventos/día de comportamiento de usuarios
- El 80% del contenido que ves lo elige el algoritmo, no tú
- Ahorró 1.000M\$/año en cancelaciones gracias a recomendaciones
- Tecnología: Spark + Kafka + Cassandra + AWS



### Tesla

- Cada coche envía millones de km de datos de conducción
- Mejora el piloto automático con datos reales en tiempo real
- Flota de 3M+ vehículos = el mayor dataset de conducción del mundo
- Tecnología: Spark Streaming + ML + almacenamiento propio



### Mercadona (España)

- Analiza el ticket de compra de 5 millones de clientes diarios
- Optimiza el lineal: cada producto en su posición exacta
- Reduce merma alimentaria un 18% con predicción de caducidades
- Tecnología: stack Big Data propio + integración con proveedores



# Los Datos como Activo Estratégico

## El nuevo petróleo del siglo XXI

- En 2006, el matemático Clive Humby acuñó la frase: "Los datos son el nuevo petróleo"
- Sin refinería (procesamiento), el petróleo bruto no vale nada — igual que los datos crudos
- Las empresas más valiosas del mundo (Apple, Google, Amazon, Meta) son empresas de datos

## Ventajas concretas que aporta Big Data

- Decisiones más rápidas y precisas: de semanas a segundos
- Nuevas líneas de negocio: monetizar datos propios como producto
- Reducción de costes operativos: mantenimiento predictivo, logística
- Personalización masiva: experiencia individual a escala de millones

## El reto: pasar de datos a valor

- Datos crudos → limpieza → transformación → análisis → decisión → valor
- Este pipeline es exactamente lo que aprenderemos a construir en este curso
- Con Scala + Spark construiremos pipelines que procesan millones de registros



# Resumen del Bloque Teórico

01

## Big Data por Sector

- Retail: stock, recomendación
- Finanzas: fraude, scoring
- Sanidad: IA, epidemias
- Telco: churn, red en tiempo real

02

## El Stack Tecnológico

- Hadoop → almacenamiento masivo
- Spark → procesamiento rapido
- Kafka → mensajería en tiempo real
- Hive → SQL sobre Big Data

03

## Datos = Valor

- Datos crudos sin procesar = 0
- Pipeline: ingesta→proceso→análisis
- Eso construiremos con Scala+Spark
- De datos a decisiones de negocio



# 01

## BLOQUE PRÁCTICO

*Investigación guiada · Mapa conceptual · Relacionar herramientas ·*

# Práctica 1 — Investiga un caso real de Big Data

Cada uno elige UNO de los 3 sectores. Investigar y preparar una presentación de 10 minutos.



## Sector A: Sanidad

- ¿Qué datos se generan en un hospital moderno?
- ¿Cómo ayuda Big Data al diagnóstico o a la gestión?
- Busca un caso real en España o Europa
- ¿Qué herramienta del stack usaría este hospital?



## Sector B: Industria / Manufactura

- ¿Qué es el mantenimiento predictivo con Big Data?
- ¿Qué datos genera una fábrica conectada (IoT)?
- Busca un caso real: Siemens, Airbus, SEAT...
- ¿Qué herramienta del stack usaría esta fábrica?



## Sector C: Smart City / Gobierno

- ¿Qué datos genera una ciudad inteligente?
- ¿Cómo usa Big Data el transporte público o la seguridad?
- Busca un caso real: Barcelona, Madrid, Bilbao...
- ¿Qué herramienta del stack usaría este ayuntamiento?



# Práctica 1 — Guía paso a paso

## Paso 1 — Elegid el sector

- Poneos de acuerdo en pareja: Sanidad, Industria o Smart City
- Anotad el sector elegido en vuestro bloc de notas

## Paso 2 — Investigad

- Buscad en Google: "[vuestro sector] + Big Data + caso real"
- Fuentes recomendadas: MIT Technology Review, Gartner...
- Anotad: nombre empresa, dato clave, herramienta usada, resultado obtenido

## Paso 3 — Preparad la presentación

- Estructura recomendada para vuestra presentación de 10 min:
  1. ¿Cuál era el problema antes del Big Data?
  2. ¿Qué datos se recogen y de dónde?
  3. ¿Qué herramienta del stack usaron?
  4. ¿Qué resultado obtuvieron? (número concreto si es posible)





# Práctica 2 — Construye el Mapa del Stack Big Data

Podéis usar papel, pizarra, Miro (miro.com), draw.io o cualquier herramienta digital.

## Paso 1 — Las capas del mapa

- Dibujad 4 capas horizontales de arriba a abajo:
- ① Fuentes de datos (apps, sensores, BBDD, logs, redes sociales)
- ② Ingesta y mensajería (Kafka, Flume, Sqoop)
- ③ Almacenamiento y procesamiento (HDFS, Spark, Hadoop)
- ④ Análisis y visualización (Hive, Tableau, Power BI)

## Paso 2 — Conectad con flechas

- Dibujad flechas entre capas: ¿cómo fluyen los datos?
- Añadid el tipo de flujo: batch (lotes) o streaming (tiempo real)
- Indicad qué capa usa Scala/Spark (spoiler: principalmente capa 3)
- Anotad junto a cada herramienta una empresa que la usa

## Paso 3 — Revisad con estas preguntas

- ¿Dónde entraría un nuevo tweet de Twitter en vuestro mapa?
- ¿Qué capa sufre más si los datos llegan corruptos (veracidad)?
- ¿En qué capa trabajaréis vosotros al terminar este curso?

## Práctica 3 — Relaciona Herramientas con Funciones

### Instrucciones

Conecta cada herramienta con su función principal

### Las herramientas

- A. Apache Spark
- B. Apache Kafka
- C. Apache Hadoop (HDFS)
- D. Apache Hive
- E. Apache Flink
- F. Tableau / Power BI
- G. Apache Cassandra
- H. Apache Sqoop

### Las funciones (une con flechas)

- 1. Almacenamiento distribuido de ficheros en disco
- 2. Procesamiento en memoria, batch y streaming
- 3. Mensajería y cola de eventos en tiempo real
- 4. SQL sobre datos almacenados en HDFS/S3
- 5. Streaming avanzado con estado y procesamiento exacto
- 6. Visualización de datos: dashboards e informes
- 7. Base de datos NoSQL para alta disponibilidad
- 8. Importar/exportar datos desde bases relacionales a HDFS

# ¡Gracias!

---

*Preguntas · Reflexiones · ¡Buen trabajo hoy!*

Día 1 completado  ·

Mañana: Desafíos Técnicos y Seguridad en Big Data