

Procesamiento Big Data con Scala

Módulo 1 · Sesión 1 · Día 1

IFCD0115 · Introducción al Procesamiento de Big Data



01

BLOQUE TEÓRICO

¿Qué es Big Data? Las 4 Vs y el ecosistema ·

¿Qué es Big Data?

¿Qué diferencia Big Data de los datos normales?

- No es solo tamaño — también velocidad y complejidad de los datos
- Los sistemas tradicionales (Excel, SQL) no pueden procesarlo

Origen del concepto

- Popularizado por Doug Laney en 2001 con las 3 Vs originales
- Hoy se habla de 4 o 5 Vs dependiendo del autor

¿Qué herramientas necesitamos?

- Ecosistema: Hadoop, Spark, Kafka, bases NoSQL
- Lenguajes: Scala, Python, Java — en este curso: Scala + Spark

Las 4 Vs del Big Data

Volumen

- Cantidad masiva de datos generados
- Desde GB hasta Petabytes y Zettabytes
- Ejemplo: Facebook genera 4 PB de datos al día

Velocidad

- Ritmo al que se generan y procesan los datos
- Datos en tiempo real: bolsa, redes sociales, IoT
- Ejemplo: Twitter procesa 500.000 tweets por minuto

Variedad

- Tipos y fuentes de datos muy distintos
- Estructurados (tablas), semi (JSON/XML), no estructurados
- Ejemplo: historial médico + imágenes + conversaciones

Veracidad

- Calidad y fiabilidad de los datos
- Los datos pueden estar incompletos o incorrectos
- Ejemplo: sensores con fallos, datos duplicados

01



Almacenamiento

- HDFS (Hadoop Distributed File System)
- Amazon S3, Azure Data Lake
- HBase, Cassandra (NoSQL)

02

Procesamiento

- Apache Hadoop (MapReduce)
- Apache Spark (nuestro protagonista)
- Apache Flink (streaming avanzado)

03



Análisis e Ingesta

- Apache Kafka (mensajería)
- Apache Hive (SQL sobre Hadoop)
- Tableau, Power BI (visualización)

Datos Tradicionales vs Big Data



Datos Tradicionales

- Tamaño: MB a pocos GB — caben en un servidor
- Estructura: tablas relacionales, esquema fijo
- Herramientas: SQL, Excel, Oracle, MySQL

Big Data

- Tamaño: TB, PB, ZB — necesita clusters de servidores
- Estructura: heterogénea — tablas, JSON, texto, imágenes
- Herramientas: Hadoop, Spark, Kafka, bases NoSQL
- Clave: escalado horizontal (más nodos) en lugar de vertical

Escalado Horizontal vs Vertical

ESCALADO HORIZONTAL EN BIG DATA (Horizontal Scaling)


COMPRENDIENDO EL CONCEPTO CLAVE DE LAS ARQUITECTURAS DE DATOS DISTRIBUIDOS

Escalado Horizontal (Big Data): [Nodo 1] + [Nodo 2] + [Nodo 3] + ... = Cluster



COMPRENDIENDO EL ESCALADO VERTICAL (TRADICIONAL)



Servidor Único Inicial
(Punto de Partida)



Capacidad Base



Servidor Único Escalado
(Resultado)



Capacidad Máxima

VENTAJAS CLAVE



Implementación
Sencilla



Menor Complejidad
de Red

*"Escalado Vertical (Tradicional):
[Servidor único] con más RAM/CPU"*

LIMITACIONES CLAVE



Límite Físico
de Hardware



Punto Único
de Falla

ECOSISTEMA DE ROLES EN BIG DATA Y IA

Explorando responsabilidades clave y herramientas tecnológicas




DATA ENGINEER

CONSTRUCTOR DE INFRAESTRUCTURA DE DATOS

- Construye pipelines de datos escalables (ETL/ELT)
- Gestiona flujos de datos masivos

Tecnologías Clave



DATA SCIENTIST

EXPLORADOR DE PATRONES DE DATOS

- Desarrolla modelos de Machine Learning (ML)
- Realiza análisis estadístico avanzado

Tecnologías Clave



DATA ANALYST

INTÉRPRETE DE DATOS EMPRESARIALES

- Crea dashboards y KPIs empresariales
- Genera informes para la toma de decisiones

Tecnologías Clave



BIG DATA ARCHITECT

ESTRATEGIA Y DISEÑO DE SISTEMAS

- Diseña y optimiza la infraestructura de Big Data (on-premise & cloud)
- Define la estrategia tecnológica de datos

Tecnologías Clave



AI ENGINEER

CREADOR DE SISTEMAS DE IA AVANZADOS

- Diseña, entrena y despliega modelos de Deep Learning
- Implementa modelos de lenguaje (LLMs)
- Establece flujos de MLOps

Tecnologías Clave





El impacto del Big Data en los sectores más importantes de la economía:



Sanidad

- Diagnóstico por IA con millones de radiografías
- Predicción de brotes epidémicos (COVID, gripe)



Finanzas

- Detección de fraude en tiempo real (miles de trans./seg)
- Algoritmos de trading de alta frecuencia (HFT)



Retail y Logística

- Recomendaciones personalizadas (Amazon, Netflix)
- Optimización de rutas y stock (Inditex, Mercadona)

Ventajas Competitivas del Big Data

¿Por qué invierten las empresas en Big Data?

- Tomar decisiones basadas en datos reales, no en intuición
- Personalizar productos y servicios a millones de usuarios
- Detectar patrones invisibles en datasets pequeños

Ejemplos reales de ventaja competitiva

- Netflix: el 80% de lo que ves viene de su sistema de recomendación
- Uber: precios dinámicos calculados en tiempo real con millones de variables
- Spotify: Discover Weekly — playlists personalizadas cada lunes

Y en España...

- Inditex (Zara): repone stock en 48h gracias al análisis de ventas
- BBVA: scoring crediticio con datos alternativos para más clientes

● Almacenamiento

- HDFS — sistema de ficheros distribuido de Hadoop
- Amazon S3 / Azure Data Lake (cloud)
- HBase / Cassandra — bases NoSQL

● Procesamiento

- Apache Hadoop (MapReduce) — batch clásico
- Apache Spark — el más rápido, nuestro foco
- Apache Flink — streaming avanzado

● Ingesta y Mensajería

- Apache Kafka — mensajes en tiempo real
- Apache Flume — ingesta de logs
- Sqoop — importar desde BBDD relacionales

● Análisis y Visualización

- Apache Hive — SQL sobre Big Data
- Tableau / Power BI — dashboards
- Jupyter Notebooks — exploración de datos



El Volumen de Datos en el Mundo

Datos que se generan cada minuto en 2024:

- Google recibe 8,5 millones de búsquedas
- WhatsApp entrega 69 millones de mensajes
- Instagram recibe 65.000 fotos nuevas
- Amazon procesa 7.900 pedidos

¿Cuánto dato existe en el mundo?

- En 2020: 40 Zettabytes (ZB) de datos globales
- Para 2030: se estiman 660 ZB
- 1 ZB = 1.000.000.000.000 GB
- Solo el 2% de todos los datos del mundo está siendo analizado. El resto: sin explotar.



Resumen del Bloque Teórico

01

¿Qué es Big Data?

- Datos masivos, veloces y variados
- Requieren nuevas herramientas
- Origen: Doug Laney, 2001

02

Las 4 Vs

- Volumen · Velocidad
- Variedad · Veracidad
- Cada V = un desafío técnico

03

El Ecosistema

- Almacenamiento: HDFS, S3
- Proceso: Spark (nuestro foco)
- Análisis: Hive, Kafka, BI

Datos Tradicionales vs Big Data

Datos Tradicionales

- Tamaño: MB a pocos GB
- Caben en un solo servidor
- Estructura: tablas con esquema fijo
- Herramientas: SQL, Excel, Oracle
- Escalado: vertical (mas RAM/CPU)
- Latencia: segundos/minutos

Big Data

- Tamaño: TB, PB, ZB
- Necesita clusters de servidores
- Estructura: heterogenea (JSON, video, texto)
- Herramientas: Spark, Hadoop, Kafka
- Escalado: horizontal (mas nodos)
- Latencia: milisegundos en streaming



01

BLOQUE PRÁCTICO

Ejercicios

Práctica 1 — Identifica las 4 Vs

Analiza 3 casos reales. Identifica las 4 Vs que aparecen.



Caso A: Hospital universitario

- 10 años de historiales (texto + imágenes)
- Datos de sensores cardiacos cada 5 segundos
- ¿Qué Vs identificas?



Caso B: Banco digital

- 2 millones de transacciones por hora
- Datos en 15 idiomas: app, web y cajeros
- ¿Qué Vs y desafíos de veracidad?



Caso C: E-commerce tipo Amazon

- Logs de clics, historial, reviews, imágenes
- Recomienda productos en menos de 200ms
- ¿Donde esta la velocidad aqui?

Práctica 2 — Mapa Conceptual del Ecosistema

Objetivo

- Construir un mapa conceptual del ecosistema Big Data

Instrucciones

- Usad papel, pizarra o una herramienta digital (Miro, draw.io)
- Conectad los conceptos: almacenamiento → procesamiento → análisis
- Añadid ejemplos reales de empresas para cada herramienta

Preguntas guía

- ¿Por qué Spark y no Hadoop para el procesamiento?
- ¿Qué pasaría si se perdieran datos en mitad del procesamiento?
- ¿Cuándo usaríamos streaming vs. procesamiento en batch?

Clasifica cada dataset y estima su escala.

Dataset 1: Tweets

- Texto, hashtags, geolocalización y emojis
- 500 millones de tweets al día
- → Tipo: _____ | Escala: _____
| Herramienta: _____

Dataset 2: Clientes bancarios

- Tabla: nombre, DNI, saldo, fecha alta
- 10 millones de clientes, actualización diaria
- → Tipo: _____ | Escala: _____
| Herramienta: _____

Dataset 3: Cámaras de tráfico

- Video HD, 500 cámaras 24/7, almacenadas 30 días
- 25 fps por cámara, resolución Full HD
- → Tipo: _____ | Escala: _____
| Herramienta: _____

¡Gracias!

Preguntas · Comentarios ·

Sesion 1 completada  ·